

¿Qué mira una CNN de vehículos? explicación local y reproducible con SHAP

REI_Tarea_AsistDev

4 de septiembre de 2026

Resumen

Este trabajo aplica SHAP (*SHapley Additive exPlanations*) a una red neuronal convolucional que clasifica imágenes de vehículos en siete clases. El objetivo no es solamente mostrar la clase predicha, sino localizar qué regiones aumentan o disminuyen la probabilidad de esa salida. Se usa un *Partition explainer* con un enmascarador de imagen por desenfoque y se verifica la propiedad aditiva de las atribuciones. En una muestra de tres imágenes, la bicicleta correcta recibe apoyo principalmente en regiones que contienen cuadro y rueda; en los dos errores, las atribuciones muestran que el contexto y las texturas de la escena también pueden mover la predicción. Estos resultados son locales: no deben confundirse con una importancia global del modelo ni con porcentajes semánticos de “ruedas” o “casco”. Todo el código, modelo, figuras y este documento están disponibles en el repositorio [GitHub del proyecto](#).

1 Motivación y pregunta

Una probabilidad de salida responde *qué* decidió el modelo, pero no explica *por qué*. En clasificación visual, la pregunta natural es:

¿Qué regiones de cada imagen favorecen o contradicen la clase predicha, y el clasificador parece usar el vehículo o el contexto de la escena?

SHAP emplea valores de Shapley para repartir la diferencia entre una predicción y una referencia entre las características. En este caso una característica no es una palabra o una columna tabular: es una región espacial de la imagen que el enmascarador puede ocultar. Por tanto, una atribución roja significa que la región empuja la probabilidad de la clase explicada hacia arriba; una azul, que la empuja hacia abajo. El objetivo es diagnosticar el comportamiento del modelo, no demostrar causalidad sobre el objeto real.

2 Materiales y configuración reproducible

2.1 Modelo y datos

El punto de partida es el notebook `vehicle-image-classification-using-cnn.ipynb`. El dataset local `Vehicles/` contiene siete directorios: *Auto Rickshaws*, *Bikes*, *Cars*, *Motorcycles*, *Planes*, *Ships* y *Trains*. Con semilla 42, se separan los ejemplos por clase en 80% para entrenamiento y 20% para validación. El notebook informa 4 454 imágenes de entrenamiento, 1 114 de validación y 22 archivos incompatibles excluidos por firma binaria. Las imágenes se redimensionan a 128×128 píxeles RGB.

La CNN tiene tres capas convolucionales de 32, 64 y 128 filtros, cada una seguida por max-pooling, global average pooling, una capa densa de 128 unidades y una salida softmax de siete clases. Durante entrenamiento se usan volteo horizontal, rotación y zoom como aumento de datos, además de `Rescaling(1/255)`. Se entrenó por tres épocas con Adam y `categorical_crossentropy`; la evaluación conservada en el notebook reporta pérdida de validación 1.4443 y exactitud 43.00%.

2.2 Muestras de explicación

Se conservan tres entradas exportadas del panel de validación del notebook: un tren etiquetado como *Trains* pero predicho como *Cars*, un barco etiquetado como *Ships* pero predicho como *Planes*, y una bicicleta etiquetada y predicha como *Bikes*. Esto permite contrastar dos errores con un acierto sin ocultar que son solamente tres casos.

2.3 Configuración de SHAP

Se ejecuta SHAP 0.46.0 con TensorFlow CPU 2.18.1. El enmascarador de imágenes de SHAP reemplaza particiones por una versión desenfocada con bloques de 32×32 píxeles (la clase usada es `Image`). El explainer particiona la imagen y estima las atribuciones con 300 evaluaciones por muestra; se fija la semilla en 42. La selección `shap.Explanation.argsort.flip[:1]` explica la salida más alta de cada imagen, es decir, la clase que el propio modelo predijo. La elección de un enmascarador de imagen y la visualización de salidas para clasificación siguen los ejemplos de la documentación oficial de SHAP [2]; la definición de SHAP se basa en Lundberg y Lee [1]. La preparación de un clasificador de imágenes convolucional sigue el flujo habitual de TensorFlow para este tipo de tarea [3].

Para una entrada x , la comprobación numérica usada es

$$f_k(x) = b_k(x) + \sum_{i=1}^m \phi_{i,k}(x), \quad (1)$$

donde $f_k(x)$ es la probabilidad de la clase k , $b_k(x)$ es la salida con la referencia enmascarada y $\phi_{i,k}$ es la contribución de la partición i . En imágenes RGB se guardan las atribuciones por canal; para resumir una región espacial se suman sus tres canales. La figura de color se normaliza por muestra solamente para hacer visibles las diferencias locales.

3 Resultados

3.1 Predicción y regiones dominantes

La Tabla 1 resume la salida que se obtuvo al volver a ejecutar el análisis sobre el modelo versionado. “Base” es $b_k(x)$ y no es la confianza de la imagen original. “Top |SHAP|” es la región 4×4 con mayor suma de atribuciones absolutas; su porcentaje se calcula dentro de esa imagen y sirve para ordenar regiones, no para declarar que una parte semántica del vehículo explica exactamente ese porcentaje.

Cuadro 1: Predicciones y concentración espacial de la atribución.

Muestra	Real	Predicción	p_k	Base	Top SHAP
Tren	Trains	Cars	0.223	0.167	inferior-centro-izquierda (38.7%)
Barco	Ships	Planes	0.522	0.562	inferior-izquierda (39.6%)
Bicicleta	Bikes	Bikes	0.643	0.235	medio-inferior-centro-derecha (16.0%)

En el tren, la atribución positiva se concentra en la parte baja izquierda, que incluye el frente del tren y texturas de vía/plataforma en la imagen redimensionada. Esa evidencia local empuja *Cars* desde una base de 0.167 hasta 0.223; no basta para afirmar que el modelo haya aprendido “ruedas de auto”. En el barco, la salida *Planes* parte de una base alta de 0.562 y las atribuciones negativas totalizan aproximadamente -0.0406 ; el casco, la vegetación y la zona inferior contradicen parcialmente esa salida, pero no lo suficiente para cambiar la clase. En la bicicleta, las atribuciones positivas se distribuyen sobre el cuadro, las ruedas y el manubrio; la clase pasa de 0.235 a 0.643.




Figura 1: Entrada y mapa SHAP para la clase predicha. Rojo favorece la clase explicada; azul la contradice. La intensidad está normalizada dentro de cada muestra para mejorar la lectura visual.

3.2 Evidencia local de los tres casos

Las figuras individuales muestran la entrada, el mapa de atribución sobre la imagen y la suma de $|\text{SHAP}|$ en una cuadrícula 4×4 . La cuadrícula es una agregación espacial reproducible, no una segmentación de “vehículo” y “fondo”.

Tren clasificado como automóvil



Figura 2: Tren real, predicho como Cars. La evidencia positiva se concentra en la zona inferior izquierda/central de esta entrada.

Barco clasificado como avión



Figura 3: Barco real, predicho como Planes. La masa negativa domina; el mapa identifica regiones que reducen la probabilidad de Planes sin que la clase correcta llegue a ser la máxima.

Bicicleta clasificada correctamente



Figura 4: Bicicleta clasificada correctamente como Bikes. El cuadro, las ruedas y el manubrio aparecen entre las zonas con mayor atribución local.

3.3 Resumen agregado de la muestra

La Figura 5 suma la magnitud absoluta de las atribuciones de las tres imágenes. El resultado sugiere que las zonas medio-inferior y superior-derecha aparecen con frecuencia en esta pequeña selección, pero no es una medida global de todo el dataset: cambiar las tres imágenes puede cambiar

el ranking. Para una conclusión global se necesitaría explicar una muestra grande y resumir por clase, con intervalos de variabilidad.




Figura 5: Ranking agregado de regiones 4×4 en las tres imágenes. Cada barra es porcentaje de |SHAP| agregado, no probabilidad.

3.4 Comprobación de aditividad

En las tres muestras la suma de la base y las atribuciones coincide con la probabilidad de la salida explicada al nivel mostrado por la ejecución: el error fue 0.00×10^0 en el CSV generado. Esto confirma que el mapa describe la salida seleccionada por el explainer; no confirma que la explicación sea causal ni que el modelo sea correcto.

4 Reproducibilidad y paquete entregable

El URL canónico del proyecto, incluido también en el resumen, es:

https://github.com/nel-eleven11/REI_Tarea_AsistDev

Desde la raíz del repositorio, el flujo completo es:

```
uv venv --python 3.10 .venv
uv pip install --python .venv/bin/python -r requirements-shap.txt
.venv/bin/python shap_analysis.py
pdflatex paper.tex
bibtex paper
pdflatex paper.tex
pdflatex paper.tex
```

El script escribe resultados JSON, CSV y NPZ dentro de `figures/shap/`, además del resumen visual y una figura por caso. El dataset completo no se versiona por tamaño; el notebook conserva el procedimiento para reentrenar si se dispone de `Vehicles/`. Las tres imágenes usadas en este paper sí están versionadas, por lo que el resultado SHAP no depende de descargar datos externos.

Existe una consideración de portabilidad: el archivo `.keras` registra una versión de Keras más nueva que la del entorno CPU usado para ejecutar esta entrega. `shap_analysis.py` intenta la carga normal y tiene un fallback que reconstruye la arquitectura conocida y carga únicamente los pesos internos; el resultado de predicción se verifica antes de explicar.

5 Limitaciones y trabajo futuro

1. **Muestra pequeña.** Tres imágenes no permiten afirmar una regla universal del clasificador. El ranking agregado solamente describe este caso de estudio.
2. **Regiones, no conceptos.** Una celda 4×4 mezcla partes del vehículo y el fondo. Para responder literalmente cuánto pesan ruedas, ventanas u orejas se necesita una segmentación o anotaciones semánticas y una definición de agregación antes de calcular SHAP.
3. **Dependencia del enmascarador.** Cambiar de desenfoque a inpainting, el tamaño de partición o el número de evaluaciones puede cambiar la distribución espacial. El mapa es relativo a la referencia elegida.
4. **Modelo modesto.** La exactitud de validación es 43.00% y la muestra contiene dos errores. Las explicaciones ayudan a diagnosticar, pero no convierten al modelo en un sistema apto para decisiones críticas.
5. **Confianza.** SHAP reparte cambios en la salida del modelo; una atribución de 0.04 no significa que la imagen tenga 4% de probabilidad de contener una parte. Probabilidad, atribución y porcentaje de masa absoluta son cantidades distintas.

6 Conclusión

La inspección SHAP responde la pregunta de manera más precisa que una lista de confianzas: muestra qué zonas apoyan la clase predicha y cuáles la contradicen. En el caso estudiado, la bicicleta correcta recibe evidencia distribuida sobre su estructura, mientras que los errores de tren y barco revelan que las texturas de la escena pueden contribuir a una clase incorrecta. La conclusión responsable es local y diagnóstica: el modelo parece usar patrones visuales concretos, pero estas tres imágenes no permiten traducirlos automáticamente en una tabla semántica de “orejas 60%” o “patas 30%”.

Referencias

- [1] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, 2017.
- [2] SHAP developers. Image examples and image plot documentation. Documentation, 2025. Accessed 2026-09-04.
- [3] TensorFlow developers. Image classification. TensorFlow Core tutorial, 2024. Accessed 2026-09-04.